

개요:

intermediate 상태변화와 리워드가 중요해진 RL 세팅,

전체 결과를 망하게 한 주범이 누군지에 대한 credit assignment 등 multi stage decision making (multi stage strategies)에서의 특징

순서: 기본 RL 구조, 벨만 Optimality,

DP(이전의 백업해둔 정보를 뒤에도 옆에도 씬)(VI),

environment가 알려진 상황에서의 RL,

state와 action space가 작은 tabular RL

5.1:

MDP정의,

unknown MDP와 상호작용하며 regret(optimal policy의 value와 내 policy의 value차이의 기댓값의 합)(=regret)을 최소화하는게 목표인 Online RL

5.2:

known MDP M 에서 내 policy의 value를 최대화하는 것 (=planning)이 DP를 통해 효율적으로 해결될 수 있다! ,

Principle of optimality (모든 state에 대해 동시에! 베스트인 policy의 존재성) (bellman optimality),

나중의 계산을 용이하게 하기 위한 Bellman Operators

5.3: Unknown MDP와 상호작용하며 regret을 최소화하는 게 목표인 Online RL에서 엡실론 그리디 방법이 안먹히는 이유 (예시)

5.4:

Performance Difference Lemma (credit assignment 메커니즘)(같은 MDP 다른 정책...의 value차이),

Bellman residual decomposition(다른 MDP 같은 정책...의 value 차이)

5.5:

ch2에서 이용한 optimism의 활용: value function(큐 바)에 대한 optimism(optimal value function 큐스타를 과대평가하도록 보장되어야 함),

보너스 function의 활용(있어야 optimism보장됨),

bellman residual을 활용해 큐바들의 self consistency 또한 보장,

LEMMA 15

5.6:

우리가 모르는 것: transition probabilities <- 빈도수를 활용해 정의내려줌,

새롭게 정의내린 transition probabilities를 활용해 새로운 MDP와 bellman operator을 정의내려줄 수 있음,

UCB-VI 알고리즘,

지켜야할 두가지(optimism, self-consistency),

bonus function(optimism을 보장해줌,

REGRET BOUND에 대한 THEOREM 1

5.6.1:

일단 t 를 고정해놓고 시작,

bonuses가 large enough해야 하는 이유(그래야 optimism 보장),

어떤 경우에 bellman residual이 bound가 되는지(그래야 self consistency 보장)

5.6.2:

regret bound $\leq$ lemma 15 $\leq$ lemma 17 $\leq \dots$ S와 A와 H에 대해 POLYNOMIAL

+) 5.5 page 88 Q&A

△ Another important aspect of the decomposition (5.23) is the *on-policy* nature of the terms in the sum. Observe that the law of s_h for each of the terms is given by executing $\hat{\pi}$ in model M . The distribution of s_h is often referred to as the *roll-in distribution*; when this distribution is induced by the policy executed by the algorithm we may have a better control of the error than in the *off-policy* case when the roll-in distribution is given by π_M or another unknown policy.

다른 policy를 가지고 학습을 시키고 싶을 때!

기존에 다른 policy를 가지고 학습시켰던 데이터를 활용해 학습시키고 싶을 때!

어떤 policy인지 모르는 파이 프라임을 가지고 데이터를 수집을 하게 되는것임. (재활용)

=> **off policy**

근데 이렇게 하려면, Q가 바라는 정의가 안됨(같은 파이를 따를 때만 Q를 함께 쓸 수 있으니깐)
그래서 IMPORTANCE SAMPLING과 같은 처리를 하게 됨.

$$\begin{aligned}\mathbb{E}_{x \sim q}[f(x)] &= \int_x q(x)f(x)dx \\ &= \int_x p(x) \left[\frac{q(x)}{p(x)} f(x) \right] dx \\ &= \mathbb{E}_{x \sim p} \left[\frac{q(x)}{p(x)} f(x) \right] \\ &\approx \sum_{i=1}^n \left[\frac{q(x_i)}{p(x_i)} f(x_i) \right].\end{aligned}$$

원래는 q distribution에 대한 접근만 가능했는데, p distribution에 대한 접근으로 해석할 수 있게 됨.

한 샘플에 대해서만 q값을 알면 됨! (원래는 q의 정확한 pmf를 알고 있었어야 함)(그냥 샘플링을 해보면 되는 문제... 근데 q(x)를 정확히 계산하려면 샘플링을 많이 해줘야하긴 함)

즉 off policy 상황에서는 bellman eq를 그대로 사용할 수 없고, 뭔가 처리를 해줘야 한다.

(5.23)(88p)의 상황: training policy랑 behaviour policy가 같은 상황! 이라 귀찮은 처리를 안해줘도 된다~!