

<7단원: RL; Function Approximation and Large State Spaces>

개요

1. Online RL인데, function approximation을 함.
 - A. 왜냐? state / action space가 더 이상 작거나 유한하거나 tabular하지 않음.
 - B. 특히, "state의 개수"랑 무관한 Regret bound를 만들고 싶음 *
2. function approximation 어케할건데?
 - A. MDP의 필수구성요소 중 하나인 "transition probability"를 직접적으로 모델링하거나
 - B. value function을 직접적으로 모델링할거임.
3. 목표는? "state space에 있어 generalize할 수 있는" 알고리즘을 만드는 것!
 - A. 8, 9, 10을 다 보지 않아도, 1~7만 봐서도 extrapolation과 같이 일반화가 가능한 것
 - B. "surprise"시킬 수 있는 state의 개수가 7정도로 (이게 나중에 rank d로 나타남) 제한되게!
-> 유효한 영향을 줄 수 있는 state의 개수에 상한이 존재함을 보일거임.

<sample complexity guarantee>

1. 강화학습 알고리즘이 원하는 성능
(최적 정책에 가까운 성능을 내거나 낮은 Regret을 달성하는 것)을 내기 위해
얼마나 많은 데이터(샘플/에피소드)를 필요로 하는지 수학적으로 보장하는 한계치
2. 얻어야 하는 이유:
 - A. 상태 공간의 무한성 극복
 - i. 실제 강화학습 환경은 상태(State)와 행동(Action)의 개수가 많거나 연속적
 - ii. 상태 수가 조금만 늘어나도 탐색해야 할 양이 기하급수적으로 증가함
함수의 복잡도(Function class complexity)에 비례하고 상태 수(S)에는 독립적인
샘플 복잡도 보장이 있어야만 거대한 환경에서도 효율적인 학습이 가능해짐
 - B. 알고리즘의 효율성 및 안전성 검증:
 - i. 샘플 복잡도 보장이 없다면 알고리즘이 언제 수렴할지, 혹은 현실적인 시간 내에 학습이 완료될 수 있을지 예측할 수 X.
이론적으로 실현 가능하고(Sample-efficient) 안전한 알고리즘을 설계하기 위해 확보해야 함.

<7.1>

1. (우리가 그동안 이거면 충분하다고 가정해왔던) realizability

- A. 기저에 있는 환경을 모델링할 수 있는 function class의 '존재성'
 - i. model realizability: true MDP를 실제로 (어딘가에) 포함하고 있는 model class M 을 '우리가 가지고 있다'
 - ii. value function realizability: true MDP의 optimal function을 실제로 (어딘가에) 포함하고 있는 state-action value class Q 를 '우리가 가지고 있다'
 - iii. policy realizability: optimal policy π_{M^*} 를 실제로 (어딘가에) 포함하고 있는 class Π 를 '우리가 가지고 있다'
- B. 이러한 realizability 가정만으로,
function class의 복잡도에만 의존하고 / state의 개수에는 의존하지 않는
regret bound를 얻을 수 있으면 얼마나 좋을까!
- C. $\ll$ 안됨 (proposition 44)
 - i. 어떤 algorithm이라도, 최소한 $\sim$ 에 scale하는 regret이 필요함
 - ii. 즉, 추가적인 구조적 가정이 필요하다!
- D. 추가적인 구조적 가정
 - i. state space에 대해 extrapolation을 가능하게 함 (generalization)
 - ii. algorithm이 마주하게 되는 state distribution중, 'effective' 한 (마주할 만한 가치가 있는, 마주하였을 때 놀랄만한, 의미있는) state distribution이 개수를 조정할 수 있게 함.

뭘 할거냐:

Linear model에서의 RL을 먼저 탐구

조금 더 일반적인, Bellman rank라는 구조적 특성을 탐구 (in nonlinear cases)

<7.2>

1. 기저에 있는 Q value function의 linearity를 가정함 (7.1)

idea here is to assume linearity of the underlying Q-function corresponding to the true model M , generalizing the linear bandit setting in Section 4:

$$Q_h^{M,*}(s, a) = \langle \phi(s, a), \theta_h^M \rangle, \quad \forall h \in [H] \quad (7.1)$$

where $\phi(s, a) \in \mathbb{B}_2^d(1)$ is a feature map that is known to the learner and $\theta_h^M \in \mathbb{B}_2^d(1)$ is an unknown parameter vector. Equivalently, we can define

$$\mathcal{Q} = \{Q_h(s, a) = \langle \phi(s, a), \theta_h \rangle \mid \theta_h \in \mathbb{B}_2^d(1) \forall h\}, \quad (7.2)$$

and assume that $Q^{M,*} \in \mathcal{Q}$. This is called the Linear-Q* model.

2. 근데 proposition 45를 보면

Q value function의 linearity만으로는 충분하지 않음.

A. 굉장히 적은 개수의 state가 있더라도 value를 측정하는 데 오래걸릴 수 있음.

B. 추가적인 구조적 가정 필요

i. 그게 LOW-RANK MDP MODEL!

3. LOW-RANK MDP MODEL

i. transition probability에도 선형성이 있음을 가정! (7.3)

mean reward에도 선형성이 있음을 가정! (7.3)

(굉장히 절박한... 가정이라고 함)

1. transition matrix의 rank가 최대 d가 됨.

→ The linear structure in (7.3) implies that the transition matrix has rank at most d , thus facilitating (as we shall see shortly) information sharing and generalization across states, (extrapolation)

2. states에 대한 generalization과 information sharing이 가능해짐.

ii. 위 가정으로 인해, (low-rank MDP)

임의의 함수에 대한 Bellman backups (대문자 TQ같은거 / ch5) 또한 선형성을 가짐.

Bellman operator 또한 선형성을 가짐 (대문자 T같은거 / ch5)

모든 정책에 대해, Q function 또한 선형성을 가짐.

Lemma 25: For any low-rank MDP $M \in \mathcal{M}$ and any $Q : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ and any $h \in [H]$, the Bellman operator is linear in ϕ :

Bellman operator는 (임의의 Q에 대해) 선형.

Bellman Operator.

$$[T_h^M Q](s, a) = \langle \phi(s, a), \theta_h^M \rangle$$

벨만 opr.의 선형성!

모든 policy에 대해, $\theta_h^{M,*}$ 는 $\mathbb{B}_2^d(1)$ 에 속함. (이것이 중요.) 모든 h 에 대해 선형.

for some $\theta_h^M \in \mathbb{B}_2^d(1)$. (In particular, this implies that for any policy $\pi = (\pi_1, \dots, \pi_H)$, functions $Q_h^{M,\pi}$ are linear (in ϕ) for every h .) Finally, for $Q : \mathcal{S} \times \mathcal{A} \rightarrow [0, 1]$, it holds that $\|\theta_Q^M\| \leq 2\sqrt{d}$.

즉, (low-rank MDP에서 모든 정책 π 에 대해) $\theta_h^{M,\pi}$ 는 선형이다!

4. LSVI-UCB 알고리즘

A. LOW-RANK MDP MODEL의 regret bound를 얻기 위한 알고리즘

- B. Least Squares Value Iteration UCB라는 뜻
- C. (일반 UCB-VI 알고리즘처럼) Optimistic property (Q value function을 과대평가)를 가짐.
- i. optimism을 보장하기 위해
기억하며 재귀적으로... dynamic programming을 하고
(Q value function에 더하는) bonus term 존재.
- D. (일반 UCB-VI 알고리즘과 다르게) Transition probability를 직접적으로 계산하지 않음!
- i. 대신, Least Square를 통해 Approximate Value Iteration 진행.
- E. 각 episode t 마다, Q바를 layer 1부터 H까지를 계산하게 됨.
어케 계산하냐?

각 layer h마다, Q바_{h+1}이 주어지는데,
Least Square를 통해 theta hat을 구하게 되고
theta hat을 요소로 가지는 linear Q-function Q hat을 구하게 됨.

구한 Q hat을 가지고,
optimistic estimate Q바_{h}를 구하게 됨. (이때, 보너스 term을 사용함)
구한 Q바_{h}를 가지고, 기억해놓고, 다음 layer인 h-1로 가서 다시 반복반복하게 됨.

각 layer마다 Q바를 구했다면,
그 episode t에 대한 optimistic policy 'pi hat'을 구할 수 있게 됨!

- F. 이렇게 optimistic policy를 구하는 LSVI-UCB방식의 REGRET bound를
proposition 46과 같이 구할 수 있음.
암튼 regret bound 구해짐.

The LSVI-UCB algorithm enjoys the following regret bound.

Proposition 46: If any $\delta > 0$, if we set $R = c \cdot d^2 \log(HT/\delta)$ (for a sufficiently large numerical constant c) and $\rho = 2\sqrt{d}$, LSVI-UCB has that with probability at least $1 - \delta$,

$$\text{Reg} \lesssim H \sqrt{d^3 \cdot T \log(HT/\delta)}. \quad (7.8)$$

5. 즉, LOW-RANK MDP라는 구조적인 가정
(Q-value function, transition prob, mean reward의 선형성)
→ (transition matrix의 rank가 최대 d라는 설정.)
을 통해
Q가 linear function에 대한 class (value function class) 일 때,

sample-efficient RL을 할 수 있다!!

6. nonlinear한 (value-) function을 다루고싶으면 어캐?
=> bellman rank 가용해서 sample-efficient RL 할 수 있음.
(기존: transition matrix의 rank가 최대 d)

<7.3> BELLMAN RANK

1. 벨만 랭크를 통해, "distribution shift"를 조정할 수 있음
 - A. 즉, 어떤 알고리즘이
개의 정책을 업데이트할 때,
완전히 새로운 distribution d 에 의해
얼마나 자주 "놀라야 하는지" (적을수록...) (유효타 제한)
를 조정하게 됨. (즉, 놀라는 횟수를 제한하게 됨 / 그 이상은 일반화)
2. Bellman Residual (EPSILON으로 표현)을 (ch5의 정의에 따라) 적었을 때,
 X 라는 embedding과 W 라는 embedding으로 나누어,
둘의 내적으로 표현할 수 있음. (7.21)

A. 즉, Bellman Residual (Epsilon)의 Rank가 d 이하임을 의미!

3. BELLMAN RANK
 - A. Bellman residual (Epsilon)의 rank의 최댓값.
 - B. d 로 표현
 - C. " X 와 W 의 내적" = "Bellman residual"이 되는
 X 과 W 가 존재하도록 하는
가장 작은 차원 d

- The utility of Bellman rank is that the factorization in (7.24) gives a way of controlling distribution shift in the MDP M , which facilitates the application of standard generalization guarantees for supervised learning/estimation. Informally, there are only d effective directions (in which we can be "surprised" by the state distribution induced by a policy π).
- 4.

5. BiLinUCB 알고리즘:
 - A. LOW-Bellman RANK MDP MODEL의 regret bound를 얻기 위한 알고리즘
(low regret을 얻게됨)
 - i. Q value function에 대한 realizability assumption O.
 - ii. 다만, regret을 직접적으로 계산하는 게 아니고

“PAC” 보장을 증명할 것임.

B. PAC: Probably approximately correct (7.25)

- i. 누적된 performance를 평가하는 게 아닌,
오직 **최종적인** performance만 평가함.

(그래서 regret bound를 낮추는 거보다 easier함)

PAC, the algorithm plays for T episodes, then outputs a final policy $\hat{\pi}$, and its performance is measured via

$$\| f^{M^*}(\pi_{M^*}) - f^{M^*}(\hat{\pi}) \| \quad (7.25)$$

That is, instead of considering **cumulative performance** (as with regret,) we are only concerned with **final performance**. For PAC, we want to ensure that $f^{M^*}(\pi_{M^*}) - f^{M^*}(\hat{\pi}) \leq \varepsilon$ for some

C. 알고리즘 개요

- i. K번의 iteration,
각 iteration때마다 n개의 episode가 있음
- ii. 현재 주어진 k번째 confidence set (Q^k)마다,
value function Q^k 를 계산하고
그에 따른 policy π^k 를 계산한다.
이때, policy π^k 는 optimistic on average하다 – w.r.t. initial state distribution

$$Q^k = \arg \max_{Q \in \mathcal{Q}^k} \mathbb{E}_{s_1 \sim d_1} [Q_1(s_1, \pi_Q(s_1))].$$

corresponding policy $\pi^k := \pi_{Q^k}$

- iii. 새로운 π^k 가 주어지면,
n개의 에피소드를 사용해
모든 function Q에 대해 Bellman Residual을 계산하여 근사한다.
-> 계산된 Bellman Residual이,
모든 정책 π (1~k)에 대해 작음!!
value function들만 모아놓은 새로운 confidence set $Q^{\{k+1\}}$ 을 만든다.

D. 결론적으로,

BiLinUCB알고리즘을 통해 얻어진

policy π hat은

PAC Guarantee를 만족한다.

이때, 에피소드 수 또한 제한적이다. (P)

Proposition 47: Suppose that M^* has Bellman rank d and $Q^{M^*,*} \in \mathcal{Q}$. For any $\epsilon > 0$ and $\delta > 0$, if we set $n \gtrsim \frac{H^3 d \log(|\mathcal{Q}|/\delta)}{\epsilon^2}$, $K \gtrsim Hd \log(1+n/d)$, and $\beta \propto c \cdot K \frac{\log|\mathcal{Q}| + \log(HK/\delta)}{n}$, then BiLinUCB learns a policy $\hat{\pi}$ such $f^{M^*}(\pi_{M^*}) - f^{M^*}(\hat{\pi}) \leq \epsilon$ PAC guarantee!! of the algorithm BiLinUCB

with probability at least $1 - \delta$, and does so using

$$\tilde{O}\left(\frac{H^4 d^2 \log(|\mathcal{Q}|/\delta)}{\epsilon^2}\right)$$

episodes.)

- E. low Bellman rank => near-optimal policy를 학습할 수 있게 함.
(또한 only depends on 1. rank d , 2. horizon H , 3. capacity $\log|\mathcal{Q}|$
=> 알고리즘이 state space에 대해 generalize될 수 있음을 의미.)
- F. Bellman rank property의 주요 역할:
눈에 띄게 다른 Bellman residual 값을 내는
state distribution이 (즉, 유효한 state distribution이)
오직 $O(d)$ 개 뿐임을 보장함.
- G. 사실 BiLinUCB 알고리즘의 regret bound를 구할 수도 있음. (PAC 말고)
구해짐.

$$\mathbf{Reg} \leq \tilde{O}\left((H^4 d^2 \log(|\mathcal{Q}|/\delta))^{1/3} \cdot T^{2/3}\right).$$

6. Bellman Rank의 예시

A. tabular MDP

Bellman rank d 가 SA라는 값에 의해 제한됨. (at most d)
(=> near-optimal policy를 학습할 수 있음을 의미)

7. Bellman Rank의 일반화 (7.3.4)

Definition 8 (Bellman rank): For an MDP M with value function class $\mathcal{Q}$ and policy class Π , the Bellman rank is defined as

$$d_B(M) = \max_{h \in [H]} \text{rank}(\{\mathcal{E}_h(\pi, Q)\}_{\pi \in \Pi, Q \in \mathcal{Q}}). \quad (7.23)$$

Equivalently, Bellman rank is the smallest dimension d such that for all h , there exist embeddings $X_h^M(\pi), W_h^M(Q) \in \mathbb{R}^d$ such that

$$\mathcal{E}_h(\pi, Q) = \langle X_h^M(\pi), W_h^M(Q) \rangle \quad (7.24)$$

- A. for all $\pi \in \Pi$ and $Q \in \mathcal{Q}$.

기존의 정의

- B. V-type Bellman rank:

[46], which asserts that for all $\pi \in \Pi$ and $Q \in \mathcal{Q}$, 모든 정책과 가치함수에 대해,

$$\mathbb{E}^{M, \pi} \mathbb{E}_{s_{h+1} | s_h, a_h \sim \pi_Q(s_h)} \left[Q_h(s_h, a_h) - r_h - \max_{a \in \mathcal{A}} Q_{h+1}(s_{h+1}, a) \right] = \langle X_h^M(\pi), W_h^M(Q) \rangle. \quad (7.40)$$

- i. Q-type 정의로는 capture되지 않는 meaningful class를 capture할 수 있음. -> 예시: Block MDP

C. Block MDP 세팅

- i. state space S: 고차원 / 넓음
dynamics: small / **latent(unobserved, 잠재된) space Z**

→ rich observations are generated from a set of unknown latent states
- ii. decodability:
unique mapping phi from S (observed state) to Z (latent state)

$$s_h \sim \underbrace{q_h^M(z_h)}_{\text{emission dist.}},$$

emission distribution / $\phi_h^M : S \rightarrow Z$

- iii. this decoder phi is not known
 1. but access to the decoder가 있음
 2. regret poly를 얻을 수 있음.
(latent state space Z에 tabular RL 알고리즘을 사용해서)
 3. 이 poly에 따라 scale하고, observed state space S의 크기에는 indep하다는 sample complexity guarantee를 얻는 게 Block MDP setting의 목적
- iv. Block MDP setting은, 계산해보면,
low V-type Bellman Rank를 만족함. (at most |Z|)

We now show that the Block MDP setting admits **low V-type Bellman rank**. Observe that we can write

$$\begin{aligned} & \mathbb{E}^{M, \pi} \mathbb{E}_{s_{h+1}|a_h, s_h \sim \pi_Q(s_h)}^M \left[Q_h(s_h, \pi_Q(s_h)) - r_h - \max_{a \in \mathcal{A}} Q_{h+1}(s_{h+1}, \pi_Q(s_{h+1})) \right] \\ &= \sum_{z \in \mathcal{Z}} \underbrace{d_h^{M, \pi}(z)}_{\text{emission dist.}} \underbrace{\mathbb{E}_{s_{h+1}|s_h, a_h \sim \pi_Q(s_h)}^M \left[Q_h(s_h, \pi_Q(s_h)) - r_h - \max_{a \in \mathcal{A}} Q_{h+1}(s_{h+1}, \pi_Q(s_{h+1})) \right]}_{\text{Bellman error}}. \end{aligned}$$

This implies that we can take

$$\underline{X_h^M(\pi)} = \{d_h^{M, \pi}(z)\}_{z \in \mathcal{Z}}$$

and

$$\underline{W_h^M(Q)} = \left\{ \mathbb{E}_{s \sim q_h^M(z)} \mathbb{E}_{s_{h+1}|s_h, a_h \sim \pi_Q(s_h)}^M \left[Q_h(s_h, \pi_Q(s_h)) - r_h - \max_{a \in \mathcal{A}} Q_{h+1}(s_{h+1}, \pi_Q(s_{h+1})) \right] \right\}_{z \in \mathcal{Z}}$$

so that the **V-type Bellman rank** is at most $(|\mathcal{Z}|)$. This means that as long as $\mathcal{Q}$ contains $Q^{M, \star}$ we can obtain sample complexity guarantees that scale with $|\mathcal{Z}|$ (rather than $|\mathcal{S}|$) as desired. ◁

1. ➔ sample complexity guarantee (state space S의 크기에 관계없고, Z에 따라 scale한다) 를 얻을 수 있음! (목적달성)
8. DEC를 사용해서 low bellman rank의 reg bound 구하기 (7.3.5.)

- A. low Bellman rank의 regret bound를 얻는 방법 중에는,
앞서 말한 BiLinUCB도 있지만
DEC를 사용할 수도 있음.

$$\mathbb{E}[\mathbf{Reg}] \lesssim H \sqrt{dT \log |\mathcal{M}|}. \quad (7.42)$$

- B. 이때,
DEC에 나오는 HELLINGER distance를
divergence로 교체해줘야
value-based guarantee를 얻을 수 있음.

divergence HELLINGER distance 대신 Value Iteration on Tailored divergence를 사용

$$D_{\text{sbr}}^{\pi}(Q \parallel M) = \sum_{h=1}^H \left(\mathbb{E}^{M, \pi} \left[Q_h(s_h, a_h) - \left(r_h + \max_a Q_{h+1}(s_{h+1}, a) \right) \right] \right)^2,$$

* Asymmetric.

which measures the squared bellman residual for an estimated value function under M .

- C. 결과적으로

This implies that **E2D.Opt**, with an appropriate choice of estimation algorithm tailored to $D_{\text{sbr}}^{\pi}(\cdot \parallel \cdot)$, achieves

$$\mathbb{E}[\mathbf{Reg}] \lesssim (H^2 d \log |\mathcal{Q}|)^{1/2} T^{3/4}.$$

라는 regret bound를 얻을 수 있음.

<결론>

Realizability만으로는 부족했다.

추가적인 구조적 가정이 필요하다.

선형성을 도입해서, Transition probability matrix의 rank가 최대 d인 세팅의 경우에, LSVI-UCB 알고리즘을 통해 Low Regret Bound를 구할 수 있고

비선형적인 함수 클래스 Q의 경우에도, 낮은 벨만 랭크

(알고리즘이 정책을 업데이트할 때 새로운 상태 분포에 의해 얼마나 많이 놀랄 수 있는지 / Dist Shift의 복잡도를 제어하는 척도 / 정책 π 와 가치함수 Q간의 잔차인 Bellman Residual (Epsilon)의 최대 rank d)

d를 가지는 세팅의 경우에, PAC guarantee(Reg Bound 대신 사용)를 만족하고 효율적인 Learning이 가능하다.